



Hochschule  
Bonn-Rhein-Sieg  
*University of Applied Sciences*

Fachbereich Informatik  
*Department of Computer Science*

## Bachelorarbeit

# Automatisches Labeln von Objekten in einer Augmented Reality Umgebung

von  
Janelle Pfeifer

Erstprüfer: Prof. Dr. Ernst Kruijff  
Zweitprüfer: Prof. Dr. André Hinkenjann  
Eingereicht am: 12. Oktober 2020

## **Erklärung**

Janelle Pfeifer  
Delpstraße 28  
53359 Rheinbach

Hiermit erkläre ich, dass ich die vorliegende Arbeit selbst angefertigt habe; die aus fremden Quellen direkt oder indirekt übernommenen Gedanken sind als solche kenntlich gemacht.

Die Arbeit wurde bisher keiner Prüfungsbehörde vorgelegt und auch noch nicht veröffentlicht.

Ort, Datum Unterschrift

**Inhaltsverzeichnis**

<b>Abkürzungsverzeichnis</b>	<b>v</b>
<b>1 Einleitung</b>	<b>1</b>
1.1 Zielsetzung . . . . .	1
<b>2 Related Work</b>	<b>3</b>
2.1 Huynh et al. (2019): In-Situ Labeling for Augmented Reality Language Learning . . . . .	3
2.2 Bell et al. (2001): View Management for Virtual and Augmented Reality . . . . .	4
2.3 Chen et al. (2018): Context-Aware Mixed Reality: A Framework for Ubiquitous Interaction . . . . .	4
<b>3 Grundlagen</b>	<b>6</b>
3.1 Grundlagen zu Augmented Reality . . . . .	6
3.1.1 Augmented Reality . . . . .	6
3.1.2 AR System . . . . .	6
3.1.3 Grundlagen zu 3D Szenen für AR . . . . .	6
3.1.4 Spatial Mapping . . . . .	7
3.1.5 View Management . . . . .	7
3.2 Magic Leap AR Brille . . . . .	8
3.2.1 Hardware . . . . .	8
3.2.2 Betriebssystem . . . . .	9
3.2.3 Unity Applikationen für Magic Leap One . . . . .	9
3.2.4 Lokale und globale Koordinatensysteme in 3D Szenen . . . . .	11
3.2.5 Kamera in 3D-Computergrafik . . . . .	11
3.3 Computer Vision . . . . .	11
3.3.1 Object Detection . . . . .	12
3.3.2 Artificial Neural Networks . . . . .	12
3.3.3 Convolutional Neural Networks . . . . .	12
3.3.4 Azure Computer Vision Services . . . . .	13
3.3.5 Azure Object Detection . . . . .	13
3.3.6 Azure Custom Vision . . . . .	14
<b>4 Umsetzung</b>	<b>18</b>
4.1 Design des Vorgang der Objekt Erkennung . . . . .	18
4.2 Architektur . . . . .	18
4.3 Interaktion . . . . .	20
4.4 Implementierung der Objekt Erkennung . . . . .	21
4.5 Ein Foto aufnehmen . . . . .	22
4.5.1 Object Detection . . . . .	22
4.5.2 Von dem Foto zum 3D Raum . . . . .	24
4.5.3 Raycast . . . . .	26
4.5.4 LabelCreator . . . . .	27
4.5.5 Azure Custom Vision . . . . .	29
4.6 Entwicklung der Foto-Repräsentation . . . . .	30
<b>5 Auswertung</b>	<b>34</b>
5.1 Laufzeitanalyse . . . . .	34
5.2 Analyse durch Azure Objekt Detection . . . . .	35
5.3 Azure Custom Vision . . . . .	35
5.4 Objekte in 3D Szene Lokalisieren . . . . .	36

<b>6 Zusammenfassung</b>	<b>38</b>
6.1 Konzepte und Impelemntierte Funktionen . . . . .	38
6.2 Ausblick . . . . .	38
<b>7 Literaturverzeichnis</b>	<b>39</b>
<b>8 Anhang</b>	<b>42</b>

**Abkürzungsverzeichnis**

## 1 Einleitung

Augmented Reality (AR) ist eine Vermischung der realen Welt mit virtuellen Elementen. Es wird durch Anzeigegeräte, wie Handys, Tablets oder Augmented Reality Brillen präsentiert und bietet ein intuitives Benutzerinterface, um Objekte der realen Welt mit Informationen anzureichern. Eine AR Umgebung bietet dem Nutzer eine erweiterte Wahrnehmung der realen Welt, indem sie diese anzeigt und gleichzeitig 3D Objekte, 2D Overlays oder Audioelemente hinzufügt.

Die Interaktion der virtuellen Elemente miteinander, mit dem Nutzer und der realen Umgebung ist ein Grundbestandteil von AR Anwendungen. Um die Interaktion mit der Umgebung zu ermöglichen müssen Informationen über die Geometrie der Umgebung vorliegen. Es gibt somit ein grobes Verständnis davon, wie ein Mesh der Umgebung aussieht.

Dieses Geometrische Verständnis kann durch ein semantisches Verständnis der Umgebung erweitert werden. Dieses ermöglicht komplexere, Interaktionen zwischen digitalen und virtuellen Elementen. Sematische Informationen über die Umgebung können durch die Gegenstände erschlossen werden, die sich darin befinden.

Es gibt mehrere Möglichkeiten Gegenstände zu erkennen. Zum einen können Markierungen in der realen Welt verwendet werden. Dabei handelt es sich um statische Bilder, beispielsweise ein Foto, oder ein QR Code, die von einer Kamera eingescannt werden. Der Marker ist einzigartig für jedes Objekt, damit sie voneinander unterschieden werden können. Der Nachteil bei diesem Vorgehen ist der Arbeitsaufwand, der damit verbunden ist, jeden Gegenstand einzeln zu markieren.

Wenn man Markierungen in der realen Welt umgehen möchte, kann man den Nutzer der Applikation bitten, beispielsweise per Geste auf Objekte der realen Welt zu weisen, die erkannt werden sollen. Für jedes der Objekte muss der Nutzer angeben, um welche Art von Gegenstand es sich handeln, damit die Applikation unterschiedliche Objekte auseinander halten kann und die korrekten Informationen mit ihnen assoziiert. Auch hier ist der Arbeitsaufwand hoch.

Beide der Verfahren lassen sich schlecht skalieren um große AR Umgebungen abzudecken. Nur eine vollautomatische Objekterkennung ist skalierbar. Damit könnte man mit deutlich weniger aufwand Semantische Informationen über eine reale Umgebung erfahren und somit Komplexere Anwendungsgebiete für AR erschließen.

Um diese Automatisierung zu erreichen, kann Image Based Object Detection aus dem Bereich der Computer Vision verwendet werden. Dieses Verfahren ist darauf ausgelegt Objekte in Bildern zu erkennen. Die Objekterkennung mithilfe von 2D Abbildungen ist am performantesten. Und Besser als versuche 3D Wolken zu interpretieren.(O'Shea und Nash 2015)

### 1.1 Zielsetzung

In dieser Thesis wird das Erkennen und Labeln von Objekten in einer AR Umgebung, mithilfe von Image Based Object Detection, automatisiert. Die AR-Brille Magic Leap One Lightwear wird als Benutzerinterface und Plattform verwendet.

Das Minimalziel besteht darin Fotos der Umgebung zu analysieren und gefundene Objekte in einer 3D Szene mit Labels zu versehen. Mithilfe der Kamera des AR Gerätes werden Fotos von der Umgebung aufgenommen. Diese Fotos werden, durch ein trainiertes neuronales Netzwerk, nach Objekten durchsucht. Diese Positionen werden in einer digitalen Abbildung der Umgebung lokalisiert und mit Labels markiert.

Das erweiterte Ziel besteht darin, ein zweites neuronales Netzwerk in die Objekterkennung einzubinden. Dieses kann trainiert werden, spezifischen Objekten zu erkennen und damit die semantischen Informationen zu erweitern, die erkannt werden können.

Als Maximalziel werden die Labels der erkannten Objekte als virtuelle Elemente mit der Magic Leap One dargestellt.

## 2 Related Work

### 2.1 Huynh et al. (2019): In-Situ Labeling for Augmented Reality Language Learning

Huynh et al. (2019) schaffen ein Framework, mit dem die Lernmethode 'loci' in Augmented Reality umgesetzt und erweitert werden kann. Die Lernmethode beruht darauf, Gegenstände der Welt mit Notizen zu beschriften.

Dafür wurde folgende automatische Real-Time Objekt Erkennung entwickelt:

Mithilfe von Image Based Object Detection werden Objekte auf RGB-Fotos der AR Umgebung erkannt. Diese Objekte werden dann in die 3D Szene der Umgebung übernommen.

Die AR Brille hat zu wenig Rechenleistung, um Image Based Object Detection durchzuführen, daher wurde eine Server-Client Architektur aufgesetzt. Die Videokamera der AR Brille wird verwendet, um Bilder von der Umgebung aufzunehmen. Die einzelnen Frames werden an den Server geschickt. Dieser nutzt ein neuronales Netzwerk, um alle erkennbaren Objekte in dem Bild zu finden und mit Bounding Boxen zu lokalisieren.

Die ObjectDetection API von TensorFlow wird verwendet. Es findet mehrere Objekte in einem Foto in einer Analyse und gibt Bounding Boxen an. Die Objekterkennung soll in Real-Time durchgeführt werden. Um die Laufzeit dieser möglichst gering zu halten, wird die niedrigste Kameraauflösung mit 896x504 Pixel verwendet und die Fotos werden als JPEG komprimiert. Damit braucht die Analyse 30 ms pro Foto. Dies ermöglicht eine Real-Time Erkennung mit 30 Frames pro Sekunde.

Trotzdem ist die Erkennung in der Applikation durch einen Netzwerk Delay von 150 ms zwischen der Hololens und dem Server verspätet.

Die Hololens nummeriert die Frames, die an den Server geschickt werden. Zusätzlich wird für jedes Frame die Kameraposition gespeichert, mit der es aufgenommen wurde. So können Frames asynchron analysiert werden.

Ist die Analyse durchgelaufen, werden die Bounding Boxen der Objekte und die Kameraposition genutzt, um die Objekte in der 3D Umgebung zu lokalisieren. Dafür wird der Mittelpunkt jeder Bounding Box mithilfe eines Raycastes in die 3D Szene projiziert.

Ein Objekt wird erst markiert, wenn es auf mehreren Fotos gefunden wurde, um Fehlern bei der Objekterkennung entgegenzuwirken. Durch die Analyse des ersten Fotos, wird eine ungefähre Position in der AR Umgebung für das Objekt ermittelt. Dieses Objekt wird dann mit den Objekten verglichen, die während der nächsten 60 Frames erkannt wurden. Haben die Objekte dieselbe semantische Bedeutung und eine ähnliche Position in der AR Umgebung, wird davon ausgegangen, dass es sich um ein einziges Objekt handelt, welches in den 60 Frames mehrmals aufgenommen wurde.

Unser Vorgehen zur Objekterkennung ähnelt dem Framework von Huynh et al. (2019). Auch hier soll die AR Umgebung durch das Hinzufügen von Labels semantisch angereichert werden. Es wird ebenfalls ein neuronales Netz verwendet, um die Object Detection auf RGB-Bildern durchzuführen. Wir haben dafür keinen eigenen Server aufgesetzt, sondern nutzen einen Cloud Service von Microsoft Azure. Durch Abspeichern von erhobenen semantischen Informationen ist eine Real-Time Detektion nicht relevant. Daher kann die Bild-Analyse länger dauern, was es erlaubt, mehrere neuronale Netze zu verwenden, die nach unterschiedlichen semantischen Informationen suchen.

In Unserem Verfahren werden erkannte Objekte schon in der Umgebung markiert, wenn sie ein einziges mal erkannt wurden. Wenn das Objekt erneut aufgenommen wird, wird die neue Analyse dem Objekt die gleiche Klasse und eine ähnliche Position der AR Umgebung zuweisen. Daran lässt sich erkennen, das es sich um dasselbe Objekt handelt.

Die Erste Position die für das Objekt berechnet wurde und die Position, die aus der zweite Aufnahme hervorgeht, unterscheiden sich mit hoher Wahrscheinlichkeit ein wenig vonein-

ander. Daher werden die Positionen gemittelt um eine akkurate Position für das Label des Objektes zu finden. (Huynh et al. 2019)

## 2.2 Bell et al. (2001): View Management for Virtual and Augmented Reality

Bell et al. (2001) beschreiben View Management für interaktive 3D Benutzeroberflächen. Als View Management wird die Positionierung von Labels bezeichnet. Die Labels können sich auf eine 2D Ebene beschränken oder im 3D Raum liegen. View Management zielt darauf ab die Labels so zu positionieren, dass sie einander und relevante reale Objekte nicht verdecken. Gleichzeitig sollen die Labels die Gegenstände der Realen Welt auf eine verständliche Art annotieren. Labels sollen nahe bei den Objekten liegen, zu denen sie gehören.

Unsere Applikation würde durch View Management profitieren. Nachdem Gegenstände in der Umgebung erkannt wurden, werden sie in dem 3D Raum durch Labels markiert. Die Lesbarkeit dieser Labels kann durch View Management verbessert werden, indem ihre Positionen über Zeit verändert werden.

Es müsste auf Veränderungen des Betrachtungswinkels und auf Hinzukommen von neuen Labels reagiert werden. Idealerweise würden die Labels einander und zusätzlich die Gegenstände der realen Welt nicht verdecken, die mit einem Label annotiert sind.

View Management geht jedoch über den Rahmen dieser Arbeit hinaus und konnte nicht implementiert werden. (Bell et al. 2001)

## 2.3 Chen et al. (2018): Context-Aware Mixed Reality: A Framework for Ubiquitous Interaction

Chen et al. (2018) stellen ein Framework vor, das einer AR Umgebung semantische Eigenschaften zuweist, um realistische Interaktionen zwischen virtuellen und realen Objekten zu erreichen. Insbesondere sollen physikalische Interaktionen an Realismus gewinnen.

Das Framework reichert die Umgebung mit Informationen über die Materialien an, aus denen reale Oberflächen und Gegenstände in der Umgebung bestehen. Die Umgebung wird in einer 3D Szene durch ein Mesh repräsentiert. Die einzelnen Voxel des Meshes werden mit Labels annotiert, um ihnen Semantik zuzuweisen.

Als beispielhafte Applikation wurde ein First-Person-Shooter vorgestellt, bei dem das Aussehen von Einschusslöchern davon abhängt auf welches Material geschossen wurde.

Für die Erkennung der Materialien werden mehrere Frames der Hololens segmentiert. Die dadurch entstehenden semantischen Informationen werden abgespeichert, um bei späteren Interaktionen der AR Applikation abgerufen werden zu können. Die Erkennung der Materialien ist nicht echtzeitfähig, aber durch das Speichern der Materialien im Raum können die Interaktionen in Echtzeit ablaufen. Die Semantischen Informationen müssen nicht mit jedem Frame bestimmt werden.

RGB-Bilder der Umgebung werden aufgenommen und mit einem neuronalen Netzwerk analysiert, um semantische Informationen zu erheben. Das neuronale Netz wurde von Chen et al. (2018) für den First-Person-Shooter aufgesetzt. Das Netz wurde darauf trainiert 23 unterschiedliche Materialien zu erkennen und Bilder nach ihnen zu segmentieren. Dabei wird für jedes Pixel ein Material angegeben.

Mithilfe der Camera Position des Frames werden die Material-Informationen auf ein 3D Modell der Umgebung, ähnlich einer Textur, projiziert. Als Resultat wird an jedes Voxel des 3D Modells ein Label pro Frame gehängt, das die semantische Information wiedergibt, die in dem Frame erkannt wurde.

Bei der Segmentierung können Fehler auftreten, bei denen das auf dem Foto erkannte Material nicht dem realen Material entspricht. Um diesen Fehlern entgegenzuwirken werden mehrere Frames aufgenommen und analysiert.

Die Informationen aus den Frames bilden sich auf die Voxel ab. Durch die Kumulierung der Segmentierungen erhält jedes Voxel eine Menge an Labels. Voxel die in schwer einzuordnenden Bildbereichen liegen, erhalten Labels die unterschiedliche Informationen beinhalten.

Um sicherzustellen, dass jedes Voxel des 3D Modells nur eine semantische Bedeutung hat, werden die gesetzten Labels mit einer Bayesian Fusion und einem neuronalen Netz überarbeitet. Als Resultat hat jedes Voxel nur ein einziges Label.

User Verfahren versucht ebenfalls das Verständnis der AR Umgebung durch semantische Informationen zu erweitern. Auch Wir nutzen ein neuronales Netzwerk um RGB-Fotos der Umgebung zu analysieren. In unserem Verfahren erhält nicht jeder Pixel semantische Informationen, sondern nur Pixel, die die Position eines Gegenstandes markieren. Daher haben nur ausgewählte Voxel des 3D Meshes ein Label.(Chen et al. 2018)

### 3 Grundlagen

#### 3.1 Grundlagen zu Augmented Reality

##### 3.1.1 Augmented Reality

Augmented Reality vermischt die reale Welt mit digitalen (virtuellen) Elementen, um dem Nutzer eine erweiterte Wahrnehmung zu ermöglichen. Es können 3D Objekte, 2D Overlays oder Audioelemente verwendet werden um eine reale Umgebung mit Informationen zu bereichern.

Die Umgebung beinhaltet den Teil der realen Welt, der in Augmented Reality abgebildet und erweitert werden soll. Beispielweise ein Zimmer, in dem eine AR Anwendung ausgeführt wird. Die AR Umgebung umfasst die reale Umgebung und die virtuellen Elemente. Augmented Reality weist drei grundlegende Merkmale auf:

- Die Realität wird mit dem Virtuellen kombiniert. Sie besteht darin, dass die Realität mit virtuellen Elementen überlagert wird.
- Interaktion mit virtuellen Elementen erfolgen in Echtzeit.
- Virtuelle Elemente haben einen festen räumlichen Platz in der AR Umgebung.

Die Merkmale unterstützen ein möglichst nahtloses verschmelzen der realen Welt mit den virtuellen Elementen.

In einer AR Umgebung kann navigiert werden, indem der Nutzer sich physikalisch durch die reale Umgebung bewegt. Die reale Umgebung und die virtuellen Elemente stehen immer in dem gleichen räumlichen Verhältnis zueinander. Für AR ist keine andere Art der Navigation möglich, da sie die Verschmelzung der realen Welt und den digitalen Elementen brechen würden.

Da die reale Welt immer zu sehen ist, gibt sie eine Referenz und einen Kontext für die virtuellen Objekte an. Beispielsweise steht die Größe von virtuellen Objekten immer in Relation zu der realen Umgebung.(Dörner et al. 2019)

##### 3.1.2 AR System

Ein AR System besteht aus der Hardware und Software, die benötigt wird um eine AR Umgebung zu erzeugen.

Das System muss die Vermischung der realen Welt mit virtuellen Elementen anzeigen und Interaktionen des Nutzers mit virtuellen Elementen, sowie Interaktion von virtuellen Elementen mit der realen Welt simulieren

Ein AR System ist in der Regel nicht an einen bestimmten Ort gebunden. Es kann in unterschiedlichen Umgebungen eingesetzt werden, die unterschiedliche reale Gegenstände aufweisen. AR Applikationen müssen diese unterstützen.(Dörner et al. 2019)

##### 3.1.3 Grundlagen zu 3D Szenen für AR

Die Virtuellen Inhalte der AR Anwendung werden in einer virtuellen Szene gespeichert. AR Anwendungen müssen in Echtzeit laufen. Daher muss die virtuelle Szene echtzeitfähig sein. Im besten Fall kann ein Nutzer keinen Unterschied zwischen der virtuellen Welt und der realen Welt bezüglich auf zeitliche Verzögerungen, bemerken.

Um Interaktion mit digitalen Elementen zu ermöglichen, werden relevante Teile der realen Welt in der 3D Szene repräsentiert. So werden beispielsweise die Wände und der Boden eines Raumes in der Szene abgebildet. Auch die Position eines Controllers und die Blickrichtung des Nutzers kann mit Sensoren verfolgt und in die Szene miteinbezogen werden.

### 3.1.4 Spatial Mapping

Um virtuelle Objekte an eine Umgebung anzupassen und Interaktion zwischen virtuellen Objekten und der realen Umgebung zu ermöglichen, benötigt ein AR System Informationen über die Geometrie der Umgebung.

Mit den Sensoren der AR Hardware werden Informationen gesammelt, die Aussagen über die Geometrie der Umgebung treffen. Beispielsweise haben AR Geräte eine Tiefenkamera, die Entfernung messen kann. Die Daten der Sensoren werden gesammelt und in Relation zu der Bewegung des Gerätes gesetzt um die Umgebung zu Rekonstruieren. Dieser Vorgang nennt sich Spatial Mapping.

Mit der Entstehenden Spatial Map können digitale Elemente mit der Umgebung interagieren, diese verdecken oder von ihr verdeckt werden.(Microsoft 2018b)




Abbildung 1: Spatial Map

### 3.1.5 View Management

Die virtuellen Informationen die einen Teil der realen Welt bereichern, werden meistens als 3D Elemente angezeigt. Die Informationen kann jedoch auch in 2D Elementen angezeigt werden, die sich auf eine 2D Ebene beschränkt. Insbesondere Labels, die reale Objekte erklären, können auf diese Art angezeigt werden.

Das Layout der 2D Elemente auf der Ebene wird durch View Management optimiert. Idealerweise werden die Elemente so positioniert, das sie sich Gegenseitig nicht verdecken, relevante Bereiche der realen Welt nicht verdecken. Zusätzlich sollen sie nah an den Gegenständen der Realen Welt bleiben, die sie annotieren. Siehe Abbildung 3.



Abbildung 2: Labels durch View Management positioniert.(Azuma und Furmanski 2003)

Das Layout muss angepasst werden, wenn sich der View verändert. Gleichzeitig soll das Layout stabil bleiben und sich nicht verändern, wenn ein Anderes Layout ein wenig besser wäre, um ein hin und her springen zwischen zwei möglichen Layouts zu vermeiden.(Azuma und Furmanski 2003)

### 3.2 Magic Leap AR Brille

Die Magic Leap One Lightwear ist eine Augmented Reality Brille, die von dem Unternehmen Magic Leap entwickelt wurde. Sie verfügt über ein Head-Mounted Display und einer Recheneinheit die über ein Kabel mit dem Display verbunden ist. Die Recheneinheit kann an der Hüfte getragen werden, was die AR Brille Mobil macht.

#### 3.2.1 Hardware

Die Recheneinheit besitzt zwei Denver 2.0 64 Bit Prozessor-Kerne und vier ARM Cortex A57 46 bit Kerne. Davon ist einer der Denver Kerne und zwei der ARM Cortex Kerne für Applikationen nutzbar.

Sie besitzt neun Sensoren und mehrere Kameras. Dazu gehören:

- ein Infrarot Tiefen-Sensor,
- ein Eye Tracker,
- eine Foto und Video Kamera, die im Format 16:9 mit einer Auflösung von 1920 x 1080 Pixeln aufnehmen und
- mehrere Umgebungskameras die in unterschiedliche Richtungen ausgerichtet sind. (MagicLeap 2018, 2020b)

Der Output geschieht über ein Display mit einem 50 Grad Field of View und einem Seitenverhältnis von 4:3. Das Display ist transparent. Daher kann die reale Welt immer betrachtet werden. Selbst wenn ein weißes Objekt angezeigt wird, schimmert die reale Welt noch durch. Das Display kann keine Schwarzen Objekte anzeigen.

Eingaben erfolgen über einen 6 Degree of Freedom Controller. Er verfügt über 3 Knöpfe (Trigger, Bumper, Home Button) und ein Touchpad. (MagicLeap 2018, 2020b)




Abbildung 3: Magic Leap One AR Brille.(MagicLeap)

### 3.2.2 Betriebssystem

Die Magic Leap Brille läuft auf dem Betriebssystem Lumin OS. Dieses wurde für Augmented Reality entwickelt und bietet Applikationen entsprechende Funktionalitäten an. Beispielsweise führt das Betriebssystem Spatial Mapping durch.(MagicLeap 2019a, 2020c) Dabei werden mit den Sensoren und Kameras der Brille Daten aufgenommen und in einen zeitlichen Zusammenhang mit der Bewegung der Brille gesetzt, um eine Rekonstruktion des Raumes zu erhalten.(MagicLeap 2019a, b, 2020a, c)

Lumin OS bietet es Applikationen an,

- Raycasts auf die Umgebung durchzuführen und
- ein Mesh der Rekonstruktion zu erhalten.

Neben dem Spatial Mapping unterstützt Lumin OS das Verarbeiten vom Input des Controllers und verwaltet die Zugriffsrechte der Applikationen. Dazu gehört beispielsweise das Recht (Permission) die Fotokamera und das Netzwerk zu nutzen.(Leap 2018; MagicLeap 2020c)

Selbst wenn mehrere Applikationen das recht dazu haben, kann nur eine Applikation zum gleichen Zeitpunkt auf die Fotokamera zugreifen. Die Applikationen müssen sich mit der Kamera-Ressource von Lumin OS verbinden, diese reguliert, welche Applikation Foto-Anfragen stellen kann und die Aufgenommenen Fotos erhält.

Es können niemals mehrere Applikationen zugriff auf die physikalische Kamera der Magic Leap One haben. Kamera Ressource Permission stufen

### 3.2.3 Unity Applikationen für Magic Leap One

Unity ist eine Entwicklungsumgebung, mit der Applikationen für Lumin OS erstellt werden können. Ein Unity Projekt besteht aus mindestens einer Szene, in der mehrere GameObjects existieren. 'GameObject' ist ein Oberbegriff für alle Elemente, die in der

Szene existieren. Sie bilden eine Hierarchische Struktur, in der GameObjects Parents und Children anderen GameObjects sind.(Unity 2017)

GameObject haben in sich keine Funktionalität und kein Aussehen. Diese werden durch Components hinzugefügt. Einige Components sind bereits in Unity integriert. Sie geben einem GameObject eine Position in der Szene (Transform Component), machen sie Sichtbar (Mesh Renderer) und führen alle sonstige Programmlogik durch, die notwendig ist. Um eine neue Funktionalitäten zu implementieren, kann ein C# Script geschrieben werden und einem GameObject als Component zugewiesen werden.

Magic Leap unterstützt die Entwicklung von Applikationen für Lumin OS mit Unity. Ein Unity Project Template von Magic Leap erleichtert das Set up der Applikation. Dazu gehören Build Optionen und das Einstellen der Haupt Kamera der Szene - der Unity Kamera. Die Unity Kamera rendert die Szene für das Display der Magic Leap One. Die Kamera verfolgt die Bewegung der Magic Leap Brille und kopiert diese in der Unity Szene.

Das Unity Template verfügt über vorgefertigte Skripts, die auf Funktionalitäten von Lumin OS zugreifen:

- MLInput stellt Informationen über den Controller zur Verfügung. Damit können die Knöpfe und Touchpad-Gesten überwacht werden.
- ML Camera greift auf die Foto-Kamera zu. Foto-Anfragen und Resultatdaten werden ebenfalls durch ML Camera behandelt.
- ML PrivilegeRequestBehavior ermöglicht es den Nutzer um das Recht zu Fragen, auf bestimmte Teile des AR Systems zuzugreifen. Beispielsweise muss nach Permission gefragt werden, um die Foto-Kamera Ressource zu verwenden.
- ML Raycast greift auf die Spatial Mapping Funktionalitäten von Lumin OS zu. Es fragt das Betriebssystem darum, einen Raycast auf die Rekonstruktion der Umgebung durchzuführen.
- ML SpatialMapper zeigt Rekonstruktion der Umgebung von Lumion OS als Mesh an. Das Mesh besteht aus GameObjects, die von ML SpatialMapper erzeugt werden. Sie werden ständig aktualisiert, um das geometrische Verständnis von Lumin OS widerzuspiegeln.

Skripts können von der Klasse Monobehavior erben. Monobehaviors verfügen über Methoden, die von Unity zu unterschiedlichen Events der Laufzeit ausgeführt werden. Nur Skripts die ein Componente eines GameObjects sind, werden aufgerufen.

- Awake - Diese Methode wird aufgerufen, wenn das GameObject initialisiert wird.
- Update - Die Update Methoden der Scripts werden zu jedem Frame aufgerufen.
- OnDestroy - Diese Methode wird aufgerufen, wenn das GameObject aus der Szene gelöscht wird.

Monobehaviors können über Globale Variablen verfügen. Wenn das Skript einem GameObject als angehören, kann der Inhalt der Globalen Variable in Unity modifiziert werden. Dadurch kann einem Skript eine Referenz auf ein bestimmtes GameObject gegeben werden.

Monobehaviors können als Singleton fungieren, indem sie eine globale statische Referenz auf sich selber anlegen, wenn ihre Awake Methode aufgerufen wird. Dadurch kann jedes andere Script, die Instanz des Singletons aufrufen, indem sie die statische Referenz der Klasse des Singletons verwenden. Skripts können während der Laufzeit GameObjects erzeugen. Um festzulegen, wie das GameObject aussehen soll, kann in dem Unity Editor ein Prefab erstellt werden. Ein Prefab ist ein vorgefertigtes, abgespeicherte GameObject, dessen Child Objects, Components und globalen Variablen der Components werden festgelegt werden. Das Prefab fungiert als Vorlage für GameObjects die zur Run Time initialisiert werden.

Während der Initialisierung wird die Position in dem globalen Koordinatensystem für das neue GameObject angegeben werden. Nachdem das Objekt initialisiert wurde, kann auf seine Components und Scripts zugegriffen werden.(Unity 2018)

### 3.2.4 Lokale und globale Koordinatensysteme in 3D Szenen

In einer 3D Szenen werden die Positionen von Objekten als Matrizen in dreidimensionalen Koordinatensystemen verwaltet. Es gibt ein globales Koordinatensystem (auch Weltkoordinatensystem oder World Space), in dem alle Objekte relativ zu einem gewählten Ursprung liegen.

Jedes Objekt hat zusätzlich ein eigenes, lokales Koordinatensystem (Objektkoordinatensystem). Dessen Ursprung liegt in dem jeweiligen Objekt. Die Position und Rotation des Objektes in dem globalen Koordinatensystem bestimmt die Relation zwischen dem globalen und dem lokalen Koordinatensystem.

Das lokale Koordinatensystem einer Kamera wird auch Camera Space genannt. Die Relation zwischen dem Camera Space und dem globalen Koordinatensystem wird in Unity durch die cameraToWorld Matrix beschrieben. Mithilfe dieser Matrix kann eine Koordinate aus dem Camera Space in die entsprechende Koordinate des globalen Koordinatensystems transformiert werden.(Unity 2020a)

Dazu wird die Koordinate als Vektor angegeben und mit der cameraToWorld Matrix multipliziert. Das Resultat ist ein Vektor, der eine Koordinate im globalen Koordinatensystem angibt.(Unity 2020a, c)

### 3.2.5 Kamera in 3D-Computergrafik

**View Frustum** ist das Teilvolumen einer 3D Szene, die auf den zweidimensionalen Bildschirm abgebildet wird. Alle Objekte die von der Kamera gesehen werden, befinden sich in dem View Frustum.

**Clipping Plane** bezeichnet eine Ebene, die den View Frustum quer zur Blickrichtung begrenzt. Es gibt eine vordere und eine hintere Clipping Plane. Die vordere Clipping Plane liegt nah an der Kamera. Alle Objekte die zwischen der Kamera und der vorderen Clipping Plane liegen, werden nicht angezeigt.

Die hintere Clipping Plane limitiert wie weit Objekte entfernt sein können, bevor sie nicht mehr zu sehen sind.

## 3.3 Computer Vision

Computer Vision setzt das Ziel die Inhalte digitaler Bilder und Videos zu verstehen. Sowohl semantische als auch geometrische Inhalte werden dabei analysiert.

Im diesem Feld kommen Statistik, Bilderverarbeitung und Maschinelles Lernen zum Einsatz. Maschinelles Lernen um neuronale Netze zu formen, die Bild und Video Analysen durchführen können. Diese Netze müssen mit großen Mengen an Beispieldaten Trainiert werden und können dann, Aufgaben, wie Objekterkennung, Menschen Erkennen und Bewegungen in Videos Nachverfolgen.(Maier et al. 2019)

Maschine Learning ist darauf ausgelegt eine automatische Entscheidung über einen Gegebenen Datensatz zu treffen. In einer Trainings Phase In Computer Vision wird maschine learning besteht die aufgabe generell darin eine automatische Entscheidung zu treffen.

Eine Grundlegende Aufgabe ist das Image Classification. Die Aufgabe besteht darin eine automatische Entscheidung zu treffen

### 3.3.1 Object Detection

Image Based Object detection reinbauen :)

Objekt Detection ist eine Aufgabe der Computer Vision. Es sollen mehrere Objekte in einem Bild erkannt werden. Spezialisierungen von Object Detection sind beispielsweise Gesichtserkennung oder Fußgänger erkennen. Durch eine Objekterkennung werden semantische Inhalte eines Bildes automatisch erhoben.

Für die Objekte wird eine Klasse und eine Bounding Box bestimmt. Die Klasse gibt an, um welche Art von Objekt es sich handeln. Beispielsweise ob es eine Tastatur oder ein Computerbildschirm ist. (Object classification) Die Bounding Box gibt ein Viereck in dem Bild an, in dem sich das Objekt befindet.(object localization)

Object Detection besteht aus drei

### 3.3.2 Artificial Neural Networks

Artificial Neural Networks sind Machine Learning Architekturen. Sie können beispielsweise Musik, Text oder Bilder nach Mustern durchsuchen. Sie sind für keine genaue Aufgabe programmiert, sondern lernen indem sie mit Beispieldaten trainiert werden.

Für jedes Beispiel gibt es ein Label, das angibt ob es das gesuchte Muster enthält oder nicht. Die Struktur des Networks verfügt über Gewichte, die Einfluss auf den Output haben. Mit jedem Trainingsbeispiel passt das Network die Gewichte an, sodass der Output dem Label des Beispiels entspricht.(Jiao et al. 2019; O’Shea und Nash 2015)

Artificial Neural Networks bestehen aus einer Menge an verbundenen Knoten, die jeweils eine Berechnung durchführen. Diese Knoten sind in Ebenen aufgeteilt, den Input Layer, den Output Layer, und mehrere Hidden Layer dazwischen. Die Knoten einer Ebene sind mit allen Knoten der Vorherigen Ebene verbunden.(Jiao et al. 2019; O’Shea und Nash 2015)

Das Neural Network bekommt eine Menge an Daten als Input. Die Knoten arbeiten zusammen um den Output zu erzeugen. Dabei wird über Gewichte entschieden, wie viel Einfluss das Ergebnis der einzelnen Knoten auf die nächste Ebene hat.(Jiao et al. 2019; O’Shea und Nash 2015)

Um ein Neural Network zu trainieren, wird der Output von einem Mensch bewertet. Das Neural Network nutzt diese Bewertung, um die Gewichte der einzelnen Knoten zu verändern. So passt sich das Neural Network an. (Jiao et al. 2019; O’Shea und Nash 2015)

### 3.3.3 Convolutional Neural Networks

Convolutional Neural Networks sind auf das Verarbeiten von Bildern spezialisiert. Sie nutzen aus, dass Bilder viele Redundanzen und informationsarme Bereiche haben. Daher können mit jedem Verarbeitungsschritt des Networks Informationen weggelassen werden. So können Rechenzeit und Volumen der Trainingsdaten verringert werden.(Jiao et al. 2019; Jmour et al. 2018; O’Shea und Nash 2015)

Convolutional Neural Networks sind Machine Learning Architekturen, die darauf ausgelegt sind, Muster in Bildern zu erkennen. Sie müssen auf das Muster trainiert werden. Dazu wird ihnen eine Menge an Bildern, die Teilweise das Muster erhalten, und der gewünschte Output, der erreicht werden soll, gegeben. Die Struktur des Network verfügt über Gewichte, die die Berechnung des Outputs beeinflussen. Mit jedem Trainingsbild passt das Network die Gewichte an, damit es die Mustern korrekt erkennen kann.(Jiao et al. 2019; O’Shea und Nash 2015)

Convolutional Neural Networks werden hauptsächlich eingesetzt um Muster in Bildern zu erkennen. Daher ist ihre Struktur und ihre Arbeitsweise auf Bilder spezialisiert. Sie brau-

chen weniger Rechenzeit und weniger Trainingsdaten als ein generelles Artificial Neural Network für dieselbe Aufgabe brauchen würde. (Jiao et al. 2019; Jmour et al. 2018; O’Shea und Nash 2015)

Die Knoten in einer Ebene eines Convolutional Neural Network sind nur mit wenigen Knoten der vorherigen Ebene verbunden. So sinkt die Menge an Informationen mit jeder Ebene. Das CNN wird gezwungen sich auf wesentliche Teile des Bildes zu konzentrieren, mit denen beispielsweise ein Objekt oder Muster erkannt werden kann. (Jiao et al. 2019; O’Shea und Nash 2015)

### 3.3.4 Azure Computer Vision Services

Über eine REST API erreichbar.

Rest steht für Representational State Transfer. Eine Rest API ist eine Programmierschnittstelle die sich am dem Verhalten des world wide web orientiert. Die Kommunikation zwischen einem client und dem server orientiert sich an REST. Rest steht für Representation State Transfer und bezeichnet einen Architekturansatz wie verteilte Systeme miteinander kommunizieren können. REST verlangt unter anderem ein Client-Server Modell eine zustandslose Kommunikationen zwischen ihnen. Jede Anfrage eines Client beinhaltet alle Informationen die der Server benötigt um sie zu beantworten.

Eine Rest-API kann mit http/s realisiert werden. Der Server / Service kann durch eine URL angesprochen werden. Diese wird auch Endpoint genannt. HTTP-Methoden, wie GET und POST kommunizieren an den Service welche Operation durchgeführt werden soll. Diese werden auch Http-Anfragen oder HTTP Request genannt. Mit Get werden Daten von dem Server angefordert. Die Post Methode erlaubt das übermitteln von zusätzlichen Daten an der Server.

Aufbau eines HTTP Requests. Start Line. HTTP methode, get, put. endpoint url. http version die die struktur der rest der nachricht definiert. headers. in den headers können beispielsweise eine autentifizierung für die API sein.

Body. Manche HTTP Methoden, wie zum beispiels POST müssen dem Server Daten übertragen. diese werden in dem Body der Nachricht untergebracht.

Auf jede Http-Anfrage wird ein HTTP-Responsecode als Antwort zurückgeschickt. Mit dem Code wird dem client mitgeteilt, ob die anfrage erfolgreich bearbeitet wurde. Wenn ein Error aufgetreten ist, gibt der Statuscode Auskunft über die Art des Errors.

Beispiel Responsecodes:

- 404 - Url nicht gefunden
- 401 - Zugriff verweigert wegen ungültiger Authentifizierung
- 400 - Fehlerhafte Anfrage. Der Service konnte die Anfrage nicht verstehen
- 200 - Anfrage wurde erfolgreich bearbeitet

Eine API wird, bei einer erfolgreichen Bearbeitung der Anfrage in dem Körper der HTTP-Response die erfragten Daten mitschicken. HTTP Response aufbau. status line gibt den response code an, die protocol version und einen status text, der den response code erklären kann. headers body. abhängig von dem response code werden in der Response Daten übertragen. diese sind im Body. Headers gegeben Art der Daten und Länge an.

### 3.3.5 Azure Object Detection

Microsoft Azure bietet einen Computer Vision Service an. Dabei handelt es sich um mehrere KIs, die für unterschiedliche Aufgaben trainiert wurden. Dazu gehört unter anderem ein Service für Object Detection.

Dabei sendet der Anwender ein Bild an Microsoft, dort wird es verarbeitet und ein Ergebnis in Form einer Json Datei zurückgeschickt.(Microsoft, 2018a, 2019a, 2020)

Die Object Detection basiert auf einem trainierten KI Modell. Dieses kann nur Objekte erkennen, für die es trainiert wurde. Zusätzlich können Objekte, die in dem Foto sehr klein sind oder nah bei anderen Objekten liegen, nicht erkannt werden.(Microsoft 2019b)

Der Service ist durch eine REST-API erreichbar. Mit einer Post Anforderung werden die Bilddaten übertragen und die Analyse angefragt. Die Response Nachricht beinhaltet eine Json-Datei, welche die gefundene Objekte und deren Positionen auf dem Foto beinhaltet. Um den Service zu nutzen wird eine Http Post Anforderung an die WebAdresse geschickt. Als Endpoint wird die Web Adresse des der REST-API Angegeben. die Nachricht muss folgenden Inhalt haben:

- Ein Authentifizierungs-schlüssel, der mit einem Azure Account verbunden ist
- und Bilddaten

Das Resultat der Analyse wird in der ResponseNachricht zurückgeschickt. Der Responsecode 200 gibt an, das die Analyse durchgeführt wurde. In diesem Falle wird eine Json Datei mitgeschickt. Beispielhaft:

```
1 {"objects": [{"rectangle": {"x": 1377, "y": 900, "w": 157, "h": 138}, "object": "computer mouse", "confidence": 0.681},  
2 {"rectangle": {"x": 1336, "y": 0, "w": 584, "h": 841}, "object": "display", "confidence": 0.873},  
3 {"rectangle": {"x": 315, "y": 25, "w": 906, "h": 622}, "object": "display", "confidence": 0.839},  
4 {"rectangle": {"x": 447, "y": 800, "w": 862, "h": 166}, "object": "computer keyboard", "confidence": 0.71}],  
5 "requestId": "a77e261a-7d40-4159-bf78-19d8fb61ad92",  
6 "metadata": {"height": 1080, "width": 1920, "format": "Jpeg"}}
```

Die gefundenen Objekte befinden sich in der Liste mit dem Key 'objects'. Jedes Element der Liste hat ein Bounding Box 'rectangle' und eine Klassenbezeichnung 'object'. Zusätzlich hat jedes Object einen 'confidence' Score. Dieser gibt die Wahrscheinlichkeit an, das das Objekt korrekt erkannt wurde. Neben den Objekten wird noch eine requestId und Metadaten über das Bild zurückgeschickt.

### 3.3.6 Azure Custom Vision

Azure bietet zusätzlich einen Computer Vision Service an, den der Nutzer trainieren kann. Das verwendete KI Modell ist für Objekt Detection entwickelt und ist nicht vor-trainiert. Custom Vision kann dann verwendet werden, wenn Azure Object Detection für Objekte nicht trainiert ist.(Micosoft 2018)

Das KI Modell lässt sich für Image Klassifizierung oder Objekt Detection trainieren. Über eine Webseite lässt sich der Trainingprozess des Modells steuern und auswerten. Der Nutzer lädt Fotos hoch und fügt jedem Foto händisch einen oder mehrere Tags hinzu. Die Tags geben die Objekt-Klasse an, die sich in dem Bild befindet. Um das Modell für Object Detection zu trainieren, kann eine rechteckige Region in dem Foto markiert werden, um das Objekt zu lokalisieren. Siehe Abbildung 4. In einem Bild können mehrere Regionen markiert werden. Jede Region wird mit einem Tag annotiert.




Abbildung 4: Trainingsbild für die Objekterkennung einer Haarbürste.

Für jede Objekt-Klasse müssen mindestens 15 Bilder hochgeladen werden, in denen der entsprechende Tag vorkommt. Nur kann kann der Trainingsprozess gestartet werden. Mit mehr Bildern in dem Trainingsset wird die Objekterkennung des Modells jedoch robuster. Azure empfiehlt es mindestens 50 Bilder pro Tag zu verwenden. Wenn mit nur wenigen Bildern trainiert wird, haben die einzelnen gewählten Bilder einen sehr großen Einfluss auf das Modell.

Durch das Trainieren wird eine Iteration des Modells erzeugt. Diese Iteration kann verwendet werden, um Objekt Detection durchzuführen. Wird erneut der Trainingsprozess gestartet, wird eine weitere Iteration erstellt. Die Iterationen werden alle unter einen Projekt ID gespeichert.

Die Iterationen des Modells werden hinsichtlich ihrer Robustheit evaluiert. Für jede Objekt-Klasse werden drei Metriken angesetzt.

- Precision - die Wahrscheinlichkeit das ein gefundenen Objekt, tatsächlich der angegeben Klasse angehört. (Die Wahrscheinlichkeit das es kein false positive ist.)
- Recall - Aus einer Menge an Objekten die einer Klasse angehören, der Prozentsatz an Objekten, die das Model korrekt lokalisieren und klassifizieren konnte.
- a.p (Average Percision) - Eine Gesamtwertung für die Evaluierung basierend auf Precision und Recall.

## Iteration 4

Finished training on **28.8.2020, 15:39:51** using **General** domain  
 Iteration id: **2254989e-9263-499a-888b-f91cc88304a4**  
 Published as: **Iteration4**



### Performance Per Tag

Tag	Precision	▲	Recall	A.P.	Image count
Haarbürste	100.0%		100.0%	100.0%	16
Nivea	100.0%		100.0%	100.0%	25

Abbildung 5: Die Evaluierung des Modells

Mit einer Erstellen Iteration des Modells können Fotos auf Objekte untersucht werden. Ähnlich wie Azure Object Detection ist das Custom Modell durch eine REST-API erreichbar. Der Endpoint beinhaltet die ID des Projektes, und die Nummer der Iteration, die verwendet werden soll. In der Post Nachricht wird ein Authentifizierungsschlüssel und ein zu analysierendes Bild mitgeschickt.

Das Resultat der Analyse ist eine Json Datei. Der Aufbau des Resultats unterscheidet sich vom dem von Azure Object Detection leicht. Informationen über die Iteration, die für die Analyse verwendet wurde werden wiedergegeben.

```

1 {"id": "9cb0cc50-1dca-4b4a-b4d1-95d6bd25c352",
2 "project": "ac915246-5268-461f-bd11-cf0c1826d509",
3 "iteration": "2254989e-9263-499a-888b-f91cc88304a4",
4 "created": "2020-10-10T02:40:40.107Z",
5 "predictions": [{"probability": 0.997380137, "tagId": "d390d34e-afc4-4ff4-8
   dcd-3ee8fe79cb8f", "tagName": "Haarbürste", "boundingBox": {"left"
   : 0.258805573, "top": 0.226171583, "width": 0.303168833, "height"
   : 0.329167157}}, {
6 {"probability": 0.0141124222, "tagId": "d390d34e-afc4-4ff4-8dc
   d-3ee8fe79cb8f", "tagName": "Haarbürste", "boundingBox": {"left"
   : 0.542580664, "top": 0.507969, "width": 0.2195471, "height": 0.3491398}}, {
7 {"probability": 0.0116642443, "tagId": "263b3042-8958-4775-9a19-
   e2602d19c9b7", "tagName": "Nivea", "boundingBox": {"left": 0.542580664,
   "top": 0.507969, "width": 0.2195471, "height": 0.3491398}}]}

```

Die gefundenen Objekte werden in der Liste "predictions" aufgezählt. Die Objekt Klassen werden in "tagName" gespeichert. "probability" gibt die Konfidenz des Modells an, das das Objekt korrekt erkannt wurde. Die erkannten Objekte müssen bei nach ihrer probability gefiltert werden, da auch Objekte mit einer sehr niedrigen probability in der Json Datei enthalten sind.

## 4 Umsetzung

Das Ziel ist das Erkennen und Labeln von Objekten in einer AR Umgebung, durch Image Based Objekt Detection.

### 4.1 Design des Vorgang der Objekt Erkennung

Im Folgenden werden die Arbeitsschritte einer Detection beschrieben.

Wenn der Nutzer das Signal gibt, beginnt die Detection. Als Erstes wird ein Foto mit der Kamera der AR Brille aufgenommen. Dieses Foto wird dann an Azure Object Detection und Azure Custom Vision geschickt. Die Services untersuchen das Foto nach Objekten, geben deren Klasse und Position auf dem Foto an.

Für jedes Objekt soll ein Label erstellt werden, die zeigt wo sich das Objekt in der realen Welt befindet. Dafür wird in der 3D Szene der AR Umgebung eine virtuelle Repräsentation des Fotos erschaffen. Die Fotorepräsentation muss die richtige Skalierung, Position und Rotation haben, um das räumliche Verhältnis zwischen der realen Foto-Kamera und der Umgebung nachzubilden.

Da die Foto-Kamera und das Display nahe beieinander liegen und den gleichen Blickwinkel haben, kann die Position des Displays als Repräsentation des Fotos genutzt werden. In der 3D Szene ist das Display mit der Hauptkamera gleichgesetzt. Die Clipping Plane der Kamera hat somit die gleiche Rotation und eine zumindest ähnliche Position und Skalierung wie das Foto.

Daher werden die Foto-Positionen auf Koordinaten der Clipping Plane abgebildet. Dabei werden verbleibende Positions- und Skalierungs-Unterschiede ausgeglichen. Für jedes Objekte wird so eine Koordinate auf der Clipping Plane bestimmt.

Als Nächstes wird ein Raycast, von der Kamera aus, durch die Clipping Plane Koordinate geschickt. Der Raycast schneidet sich mit einem Mesh, das die reale Welt abbildet. Die getroffene Position wird mit einem Schriftzug markiert. Dort befindet sich das Objekt, das auf dem Foto gefunden wurde.

Alle Objekte, die Azure Object Detection und Azure Custom Vision gefunden haben, werden so für den Nutzer in der AR Umgebung markiert.

### 4.2 Architektur

Magic Leap One übernimmt alle Berechnungen im 3D Raum und führt Spatial Mapping durch. Das Analysieren von 2D Fotos wird an eine REST-API delegiert, da es sehr Speicher und rechenintensiv ist. Die Magic Leap wird als Interaktionsmöglichkeiten für den Nutzer verwendet und zeigt die Ergebnisse der Objekt Detection an. Ergebnisse und Zwischenstände der Objekt Erkennung werden mit einem UI Element angezeigt in der Szene angezeigt. Siehe Abbildung 6




Abbildung 6: Diagramm der Architektur inklusive Bearbeitungsschritte und Informationsweitergabe.

Das Projekt wurde in Unity umgesetzt und für die Magic Leap AR Brille entwickelt. Es wurde ein Unity Projekt Template von Magic Leap verwendet.

Zusätzlich werden einige vorgefertigte Klassen von Magic Leap verwendet. Dazu gehören MLInput, ML Camera, ML Raycast, ML PrivilegeRequestBehavior und ML SpatialMapper. Diese Klassen greifen auf Funktionalitäten des Lumin OS zu.

Die Benötigten Funktionalitäten der Applikation wurden in mehreren Script-Klassen umgesetzt. Der Großteil der Scripts verhält sich wie Singletons. Sie existieren nur einmalig in der Szene.

Das Klassendiagramm auf Abbildung 7 zeigt die Scripts und ihre Relationen zueinander.




Abbildung 7: Klassendiagramme der Scripte

Die Klassen InputHandler, MoveDisplay, LabelCreator, InformationUI und MarkerBehavior sind für die Interaktion mit dem Nutzer zuständig.

TakePicture, SavedCameraState, AzureCustomPredicton, AzureObjectDetection, PixelToWorld und Raycast führen das Erkennen von Labels von Objekten anhand eines Aufgenommenen Fotos durch. Der Prozess wird durch den InputHander gestartet.

Wurde ein Objekt erkannt und eine Position auf dem Mesh der Umgebung bestimmt, wird der LabelCreator aufgerufen. Es erzeugt das Label mit dem entsprechenden Text.

MarkerBehavior ist eine Script das jedes Label GameObject hat, das erzeugt wird. Über das MarkerBehavior kann der Schriftzug des Labels angepasst werden.

## 4.3 Interaktion

InputHander verarbeitet den Input des Nutzers und startet entsprechende Aktionen durch die MoveDisplay und TakePicture Klassen. MLInput ist eine vorgefertigte Klasse von Ma-

gic Leap. Sie stellt Informationen über den Zustand des Controllers zur Verfügung. InputHander überwacht den Controller und startet die Aktionen, wenn die entsprechende Taste gedrückt wurde.

- Trigger: Objekt Erkennung starten mit TakePicture
- Home Button: UI Element Mittig vor das Display setzen.
- Bumper: Labels verstecken
- Bumper halten: zuletzt erzeugten Label entfernen

Das UI Element wird von InformationUI gesteuert. TakePicture nutzt InformationUI um das zuletzt aufgenommene Foto anzuzeigen. AzureCustomPrediction, Azure ObjectDetection und PixelToWorld dokumentieren ihre Arbeitsschritte mit dem UI Element und der LabelCreator lässt eine Liste aller Labels anzeigen, die in der Szene existieren. Siehe Abbildung ??.

Der LabelCreator ist für das erstellen der Labels verantwortlich und sorgt dafür, dass die Labels für den Nutzer lesbar sind. Dafür werden die Labels in Richtung der Kamera ausgerichtet und mitgeführt. Des Weiteren kann der LabelCreator Labels verstecken und entfernen.

Neben dem UI Element und den Labels wird auch ein Mesh angezeigt, das die Spatial Map der Umgebung wiedergibt. Das Spatial Mapping wird von Lumin OS durchgeführt und das Mesh wird durch die MLSpatialMapper Klasse von MagicLeap erzeugt.



Abbildung 8: Ausgabe

#### 4.4 Implementierung der Objekt Erkennung

Im folgenden werden die Scripts besprochen die für die Objekt Erkennung zuständig sind.

#### 4.5 Ein Foto aufnehmen

Das Script TakePicture implementiert das Aufnehmen eines Fotos. Dabei wird ML Camera von MagicLeap genutzt, um die Kamera der Magic Leap Brille anzusteuern. Wenn die Applikation gestartet wird, stellt dieses Script sicher, dass die Applikation Permission hat die Kamera zu nutzen. Dann verbindet sich das Script über MLKamera mit der Kamera Ressource. Die Kamera Ressource wird wieder abgegeben, wenn die Applikation terminiert oder pausiert wird.

Wenn die Methode TakeImage aufgerufen wird, startet der Prozess der Objekt Erkennung. Das aufnehmen der Fotos geschieht asynchron. Für jedes Foto wird ein Thread erzeugt, in dem ML Camera ein Foto aufnimmt. In diesem Thread wird zusätzlich die Aktuelle Position der Unity Kamera als SavedCameraState gespeichert.

Die Methode OnCaptureRawImageComplete wird von ML Camera aufgerufen, wenn das Foto fertig ist. Die Daten des Bildes und der SavedCameraState werden von dort aus an die Scripts AzureObjectDetection und AzureCustomPrediction weitergegeben. Dort wird die Analyse der Bilder gestartet.

##### 4.5.1 Object Detection




Abbildung 9: Klassendiagramm AzureObjectDetection

In der Methode AnalyseImage von AzureObjectDetection wird ein Web Request zusammengestellt, um die Azure REST API anzufragen. Der Request enthält einen Authentifizierung für die API und das zu analysierende Foto.

Der Webrequest wird verschickt und auf die Antwort gewartet. Wenn die Antwort eintrifft, wird anhand des ResponseCodes geprüft, ob es bei dem Request einen Fehler gab. Beispielsweise kann die Internetverbindung gestört sein oder die Authentifizierung abgelehnt werden. Wenn es keinen Fehler gab, wurde eine Json-Datei bei der Antwort mitgeschickt. Darin wird für jedes gefundene Objekt auf dem Foto eine Bezeichnung (Klasse) und eine Bounding Box angegeben.

Die Json-Datei wird in HandleJsonResponse verarbeitet. Für den erwarteten Aufbau der Datei wurden drei Klassen geschrieben. Der Json String wird mit JsonUtility in ein Detec-

tionResponse Object umgewandelt. Dabei werden alle gefundenen Foto-Objekte in einer Liste von DetectedObjects abgelegt. Siehe Abbildung 10. (Unity 2020b)




Abbildung 10: Umwandeln der Json Datei in Objekte.

Die gefundenen Objekte sollen im 3D Raum mit einem Label gekennzeichnet werden. Dafür wird für jedes DetectedObject die Methode Cast von der Klasse PixelToWorld aufgerufen. Der Methode wird der Mittelpunkt der BoundingBox als u,v Foto-Koordinate für das DetectedObject übergeben. Siehe Abbildung 11.

```

81     public void HandleJsonResponse(System.String jsonResponse, SavedCameraState cpos)
82     {
83         jsonResponse = jsonResponse.Replace("object", "objectName");
84         //c# doesn't like "public string object"
85         DetectionResponse det = new DetectionResponse();
86         det = JsonUtility.FromJson<DetectionResponse>(jsonResponse);
87         InformationUI.instance.Show(" Handle Json");
88         foreach (DetectedObject obj in det.objectNames)
89         {
90             Debug.Log(obj.objectName);
91             int x = obj.rectangle.x + (obj.rectangle.w / 2);
92             int y = obj.rectangle.y + (obj.rectangle.h / 2);
93             InformationUI.instance.Add(obj.objectName);
94             PixelToWorld.instance.Cast(x, y, cpos, obj.objectName);
95         }
96     }
  
```

Abbildung 11: Umwandeln der Json Datei in Objekte.

#### 4.5.2 Von dem Foto zum 3D Raum




Abbildung 12: Klassendiagramm PixelToWorld

Ein gefundenes Foto-Objekt soll in der 3D Abbildung der realen Welt lokalisiert werden. Dafür nutzt die Methode Cast die u,v Foto-Koordinate des Objekts und einen SavedCameraState. Der SavedCameraState beschreibt die Positiong der Unity Kamera zu dem Zeitpunkt als das Foto aufgenommen wurde. SavedCameraState beinhaltete die cameraToWorldMatrix und den Ursprung der Kamera.

Das Foto kann mit dem Display und somit mit der Clipping Plane der Hauptkamera approximiert werden. Die u,v Foto-Koordinate wird zunächst in eine x,y,z Koordinate in dem Camera Space umgewandelt. Der z Anteil gibt die Entfernung von dem Ursprung der Kamera an in Blickrichtung an. Dabei befinden sich Punkte mit einer Entfernung von 0.4 Einheiten auf der Clipping Plane. In dem Camera Space mit  $z = -0.4$  angegeben.

Die x und y Dimensionen beschreiben die Achsen, die horizontal und vertikal zur Clipping Plane verlaufen. Mit dem festgelegten  $z = -0.4$ , kann jeder Punkt auf der Clipping Plane durch x und y angegeben werden. Dazu gehören auch Punkte die außerhalb des View Frustum liegen.

Es wurden Werte für x und y ausprobiert, mit denen die Ränder des Fotos auf der Clipping Plane angegeben werden können. Dabei wurde auf die unterschiedlichen Seitenverhältnisse des Fotos und des Displays geachtet. Darüber hinaus ist der Bildausschnitt des Displays kleiner. Daher liegen die Ränder des Fotos außerhalb des View Frustum.

Sind diese x und y Werte bekannt, ergibt sich für die Achsen jeweils ein Intervall, die kombiniert alle Foto-Koordinaten auf die Clipping Plane abbilden können. Die Intervall lauten:  $[-0.295, 0.2281]$  für x und  $[0.1546, -0.1507]$  für y. Mit den Intervallen wird die Position und Skalierung des Fotos in Relation zu dem Display - und der Hauptkamera - berücksichtigt.

Siehe Kapitel 4.6 für die Entwicklung der Cast Methode und die Ermittlung der Intervallwerte.

Es werden zwei lineare Funktionen aufgestellt:

- Die Funktion X bildet das Intervall für u [0,1920] auf das Intervall für x [-0.295,0.2281] ab.
- Die Funktion Y bildet das Intervall für v [0,1080] auf das Intervall für y [0.1546,-0.1507] ab.

Siehe Abbildung 13.

```

40 //Picture u and v ranges
41 private float umin = 0;//left
42 private float umax = 1920;//right
43 private float vmin = 0;//up
44 private float vmax = 1080;//down
45 //Offset Vektor x and y ranges
46 private float xmin = -0.295F;//left
47 private float xmax = 0.2281F;//right
48 private float ymin = 0.1546F;//up
49 private float ymax = -0.1507F;//down
50 private float X(float u)
51 {
52     float slope = ((xmax - xmin) / (umax - umin));
53     float b = xmin - slope * umin;
54     return slope * u + b;
55 }
56 private float Y(float v)
57 {
58     float slope = ((ymax - ymin) / (vmax - vmin));
59     float b = ymin - slope * vmin;
60     return slope * v + b;
61 }
```

Abbildung 13: Funktionen X und Y

Mit den Funktionen wird eine Koordinate im Camera Space für u,v berechnet. Diese Koordinate wird dann, mithilfe der cameraToWorldMatrix des SavedCameraState, in die Koordinate p des globale Koordinatensystem umgewandelt. Damit wird die Position und Rotation der Kamera - und somit des Fotos - in der 3D Szene berücksichtigt. Siehe Abbildung 14.

```

28 public void Cast(float u, float v, SavedCameraState cpos, GameObject clippingPlaneMarker,
29                     string objectName, bool showClippingPlane, int material)
30 {
31     //scale v,v to x,y range
32     Vector3 offset = new Vector3(X(u), Y(v), -0.4F);
33     Vector3 p = cpos.cameraToWorldMatrix.MultiplyPoint(offset);
34     Raycast.instance.StartCast(Raycast.instance.CreateRaycastParams(cpos.ctransform, p), objectName, material);
35     if (showClippingPlane)
36     {
37         GameObject sphere2 = Instantiate(clippingPlaneMarker, p, Quaternion.identity); // show point on clipping
38     }
39     ResultAsText.instance.Add(u + " " + v + " " + X(u) + " " + X(v) + " " + objectName + " object marked");
40 }
```

Abbildung 14: Cast Methode

### 4.5.3 Raycast




Abbildung 15: Klassendiagramm Raycast

Als Nächstes wird ein Raycast durch den Ursprung der Kamera und die Koordinate p gesendet. MLRaycast wird genutzt, um einen Schnittpunkt mit der Rekonstitution der Welt von Lumin OS zu bestimmen. Die Stelle, die der Raycast trifft beschreibt die Position des DetectedObject im 3D Raum.

Für den MLRaycast werden zwei Parameter benötigt:

- Ein QueryParams Objekt, das Ursprung und Richtung für den Raycast beinhaltet.
  - Ursprung: Kameraursprung aus SavedCameraState
  - Richtung: Richtungsvektor von dem Kameraursprung zu der Koordinate p
- Eine Methode die aufgerufen wird, wenn der Raycast fertig ist.
  - Callback Methode: HandleOnRecieveRaycast

Siehe Abbildung 16.

```

19     public MLRaycast.QueryParams CreateRaycastParams(Transform ctransform, Vector3 target)
20     {
21         MLRaycast.QueryParams _raycastParams = new MLRaycast.QueryParams
22         {
23             // Update the parameters with our Camera's transform
24             Position = ctransform.position,
25             Direction = target - ctransform.position,
26             UpVector = ctransform.up,
27             // Provide a size of our raycasting array (1x1)
28             Width = 1,
29             Height = 1
30         };
31         return _raycastParams;
32     }

```

Abbildung 16: Cast Methode

Wenn der Raycast fertig ist, wird die Methode HandleOnRecieveRaycast aufgerufen. Der Parameter point beinhaltet dabei die getroffene Koordinate. Diese wird an die Methode CreateMarker von der Klasse LabelCreater weitergegeben.




Abbildung 17: Markierungen in der Welt

#### 4.5.4 LabelCreator

CreateMarker erhält den Punkt point, der getroffen wurde und die Bezeichnung für das DetectedObject. An der Koordinate von point wird ein Prefab GameObject instanziert, das als Markierung für das DetectedObject in der 3D Umgebung dient.

Das Prefab besteht aus einer Kugel und einem Schriftzug, der den Namen des DetectedObject anzeigen soll. Dem neu instanzierten GameObject wird die Bezeichnung des DetectedObject als Schriftzug zugewiesen. Siehe Abbildung 18.




Abbildung 18: Labels in der Welt

Wenn ein Label nahe eines anderen Labels erzeugt werden soll, das denselben Schriftzug hat, wird davon ausgegangen, dass ein Objekt der Realen Welt zum zweiten mal erkannt wurde. Daher wird kein neues Label erstellt, sondern das alte Label modifiziert. Die Positionen an denen das Objekt in der Szene lokalisiert wurde werden mit jeweils einer grauen Sphäre markiert und das Label wird in den Mittelpunkt der grauen Sphären gesetzt. So wird die Position des Objektes genauer, wenn es häufiger Erkannt wurde. Siehe Abbildungen 19 und 20.




Abbildung 19: Haarbürste zwei mal Erkannt




Abbildung 20: Haarbürste drei mal Erkannt

Die erzeugten Labels werden in den Listen `MarkerCustomPrediction` und `MarkerObjectDetection` gespeichert, je nachdem welcher Azure Service verwendet wurde. Die Listen werden genutzt, um die Labels zu der Unity Kamera auszurichten damit sie lesbar sind.

#### 4.5.5 Azure Custom Vision

Neben der Bildanalyse mit Azure Object Detection wird auch Azure Custom Vision verwendet. Die AI wurde über die Webseite trainiert.

Die Anfrage an den Service passiert in der Klasse AzureCustomPrediction. Ähnlich wie bei AzureObjectDetection wird ein Webrequest erstellt mit einem Authorization Key für den Service und einem Foto als Payload.

In der Antwort wird eine Json Datei zurückgeschickt, die die gefundenen Objekte angibt. Da die Json Datei ein etwas anderes Format hat, wurde eine eigene HandleJsonResponse Methode dafür geschrieben.

Für jedes erkannte Objekt wird die Methode Cast von PixelToWorld aufgerufen, um das Objekt in der realen Welt zu lokalisieren und zu markieren.

**Das Trainieren** Es wurde probiert das Custom Vision Modell auf drei unterschiedliche Objekte zu trainieren. Dabei wurden vier Iterationen erstellt.

Iteration 1:

Zunächst wurde probiert Tuben von Acrylfarbe zu erkennen. Die Genauigkeit davon war nicht sehr hoch. Es wurden in Fotos Acrylfarben an Stellen erkannt, an denen es keine gab. Siehe Abbildung 21.




Abbildung 21: Beispieldfoto Iteration 1. Die Wasserflasche wurde als Farbe markiert mit 55.7 Prozent statistischer Konfidenz. Die tatsächliche Farbtube wurde mit einer Konfidenz von 47.5 Prozent erkannt.

**Iteration 2** In der zweiten Iteration wurde probiert das Modell darauf zu trainieren, eine blaue Dose von Nivea Hautcreme zu erkennen. Die Form und Farbe der Dose ist sehr simpel, daher wurde davon ausgegangen, dass sie leichter zu erkennen ist. Die berechnete Prediction Wahrscheinlichkeit während des Trainings lag bei 80 Prozent.

Trotzdem wurden in vielen Fotos fälschlicherweise Nivea Dosen erkannt.

**Iteration 3** In der dritten Iteration wurde versucht die vorherige Iteration zu verbessern. Es wurden ausgewählte Trainingsfotos entfernt, die die Dose von einem seitlichen Winkel zeigten. Die Erwartung war, dass die Detektion der Dose aus dem Blickwinkel von Oben konsistenter wird. Zusätzlich wurden mehr Fotos von der Dose auf unterschiedlich gefärbten und gemusterten Untergründen hinzugefügt.

Die Genauigkeit der Prediction sank auf 75 Prozent.

**Iteration 4** In der vierten Iteration wurden zwei Fotos von der Nivea Dose entfernt, was die Genauigkeit auf 100 Prozent steigen ließ. In der Umsetzung mit der Magic Leap Anwendung wurden trotzdem häufig Objekte fälschlicherweise als Nivea Dose markiert.

Neben der Dose wurde diese Iteration darauf trainiert eine bestimmte Holzhaarbürste zu erkennen. Aufgrund von dem komplexeren, und markanten Aussehen der Bürste wurde davon ausgegangen, das die Bürste besser von anderen Objekten zu unterscheiden ist. Die Bürste wurde nur mit den Borsten nach oben fotografiert.

Die Genauigkeit für die Bürste lag bei 100 Prozent. In der Umsetzung mit der Magic Leap Anwendung wird die Bürste häufig nicht erkannt, obwohl sie im Bild ist und mit den Borsten nach oben liegt. Es werden jedoch keine Objekte fälschlicherweise als Haarbürste erkannt.

#### 4.6 Entwicklung der Foto-Repräsentation

Um die u,v Foto-Koordinate eines gefundenen Objektes auf der Clipping Plane der Kamera zu lokalisieren, wurden ein paar Herangehensweisen ausprobiert.

Das Ziel ist das Setzen einer Markierung in dem 3D Raum, basierend auf der Foto-Koordinate. Das Foto beinhaltet keine Information über die Entfernung zu dem Objekt. Dafür muss ein Raycast durchgeführt werden.

Mit einer Repräsentation des Fotos in dem 3D Raum ist es möglich diesen Raycast durchzuführen. Dazu muss das Foto nicht tatsächlich in dem 3D Raum vorhanden sein. Es muss jedoch mit dem Input einer Foto-Koordinate ein Output einer Koordinate in dem 3D Raum erzeugt werden, mit dem der Raycast durchgeführt werden kann.

Die Position des Fotos hängt mit der Kamera zusammen, daher kann das Foto durch den Camera Space simuliert werden. Als erstes wurde probiert ein Sphären-Objekt an eine gezielte Koordinate des Camera Space zu bewegen.

Wenn die Kamera am Ursprung des globalen Koordinatensystem liegt und eine neutrale Rotation hat, stimmt der Camera Space mit dem globalen Koordinatensystem überein. Die Sphäre wurde in der Szene per Hand bewegt um markante Koordinaten des Camera Space abzulesen. Siehe Abbildung 22.




Abbildung 22: Die Blaue Sphäre liegt auf dem Rechten Rand der Clipping Plane.

Dabei wurden folgende Camera Space Koordinaten gefunden:

- Near Clipping Plane bei  $z = -0.37$
- linker Rand bei  $x = -0.153$
- rechter Rand bei  $x = 0.153$
- oberer Rand bei  $y = 0.1147$
- unterer Rand bei  $y = -0.1147$

Die x und y Koordinaten hängen von der u,v Koordinate des Fotos ab. Es wurden lineare Funktionen aufgestellt um u,v auf x,y abzubilden. Diese Abbildung dient als Repräsentation des Fotos im 3D Raum, unter Berücksichtigung der Position und Skalierung des Fotos im Verhältnis zu der Kamera.

Dann wurde getestet wie genau DetectedObjects in der AR Umgebung lokalisiert werden. Es wurden testweise Fotos aufgenommen, analysiert und die DetectedObjects markiert. Die entstandenen Markierungen lagen in Sichtfeld, jedoch nicht an den erwarteten Stellen.

Um dem Problem auf den Grund zu gehen, wurde ein UI Objekt erstellt, das ein aufgenommenes Foto bei Runtime anzeigt. Das Foto wurde dann mit dem Display verglichen. Dabei fiel auf, dass sie ein unterschiedliches Seitenverhältnis haben und das Display einen kleinen Bildausschnitt zeigt.

Es gibt zwei Möglichkeiten die Unterschiede zwischen Foto und Display auszugleichen. Entweder wird das Foto auf das Display zugeschnitten oder das gesamte Foto wird verwendet. Im zweiten Fall würden auch Objekte erkannt, die außerhalb des Sichtfeldes liegen. Es wurde die Entscheidung getroffen das Foto zuzuschneiden. Damit gibt es ein besseres Feedback für den Nutzer, wenn ein Objekt gefunden wurde.

Das Zuschneiden wurde realisiert, indem die Intervalle für u und v der Abbildungsfunktionen stärker eingegrenzt wurden. Alle Objekte die außerhalb der Intervalle liegen werden ignoriert. Um die Intervalle zu bestimmen wurde dem Fotoanzeige-UI-Element ein Gitter hinzugefügt. Mit dem Gitter kann die u,v Position von beliebigen Stellen des Fotos abgelesen werden. Durch Aufnehmen von Fotos und Vergleichen mit dem Sichtfeld des Displays wurde abgelesen, bei welcher u,v Position des Fotos die Ecken des Displays zu finden sind. Die Intervalle wurden dem entsprechend eingegrenzt.

Mit den durchführten Veränderungen der Intervalle konnten DetectedObjects korrekt in der Umgebung lokalisiert werden. Jedoch wurden sehr häufig Objekte nicht markiert, obwohl sie im Sichtfeld des Nutzers lagen, weil deren Mittelpunkt außerhalb eines Intervalls lag.

Daher wurde entschieden die zweite Möglichkeit zu implementieren und das gesamte Foto zu verwenden und Objekte auch zu markieren, wenn sie komplett außerhalb des Sichtfeldes liegen. Dafür wurden die Intervalle für u und v wieder auf die ursprünglichen Werte - [0,1920] und [0,1080] - gesetzt. Die Intervalle für x und y mussten vergrößert werden.

Um die x und y Intervalle bestimmen zu können, wurde das Fotoanzeige-UI-Element Parallel zu der ClippingPlane gelegt. Das Element folgt den Bewegungen der Kamera und liegt möglichst nah an der Near Clipping Plane. Das Display der Magic Leap Brille zeigt selbst solide Objekte leicht durchsichtig an. Das wurde genutzt, um Fotos aufzunehmen, mit dem UI Element anzuzeigen und mit der realen Welt zu vergleichen. Durch Ausprobieren wurde das UI Element so skaliert und verschoben, dass das angezeigte Foto mit der realen Welt soweit wie möglich übereinstimmt. Siehe Abbildungen 23 und 24.




Abbildung 23: Das Aufgenommene Foto füllt das gesamte Display aus, wenn es angezeigt wird. Die Blaue Sphäre liegt auf dem Rechten Rand des Foto-Anzeige-Elementes.




Abbildung 24: Die Blaue Sphäre befindet sich nicht mehr in dem View Frustum und das Foto-Anzeige-Element befindet sich ein wenig hinter der Near Clipping Plane.

Dann wurden die Ränder des UI Elementes genutzt um die Intervalle für x und y zu bestimmen.

- für x: [-0.295, 0.2281]
- für y: [0.1546, -0.1507]
- Zusätzlich wurde z = -0.4 gesetzt. Das UI Element musste ein wenig weiter von der Clipping Plane entfernt sein um angezeigt zu werden.

Mit diesen Intervallen für u,v,x und y konnten DetectedObjects gut lokalisiert werden und es wurden keine Objekte mehr weggelassen, von denen der Nutzer erwarten würden, dass sie markiert werden.

## 5 Auswertung

in welchem raum getestet. wie groß sind die fotos?

### 5.1 Laufzeitanalyse

Die Laufzeit von dem Aufnehmen und Analysieren eines Fotos bis hin zur Label Erstellung in der Szene wurde aufgezeichnet. Siehe Abbildung 25




Abbildung 25: Durchlauf mit Laufzeit Aufzeichnung

Über 11 Aufgenommene Fotos wurden gefunden, das das Aufnehmen des Fotos im Durchschnitt 0,9 Sekunden dauert. Das Anfragen des Azure Object Detection Services, inklusive Netzwerk Response Time liegt durchschnittlich bei 1,01 Sekunden. Die Anfrage an den Azure Custom Vision Service, inklusive Netzwerk Response Time, dauert im durchschnitt 1,28 Sekunden.

Das auslesen der Json Antworten, lokalisieren der Objekten in der 3D Szene und das Label erstellen, benötigt weniger als eine Mikrosekunde.

Insgesamt dauert das Aufnehmen und Analysieren eines Fotos somit durchschnittlich 3,19 Sekunden. Siehe Abbildung 26 und 27.

	Foto 1	Foto 2	Foto 3	Foto 4	Foto 5	Foto 6	Foto 7	Foto 8	Foto 9	Foto 10	Foto 11	Average
image capture	0,82	1,18	0,89	0,75	1,57	0,80	0,74	0,89	0,77	0,75	0,76	0,90
obj det web request	0,86	0,84	1,11	1,30	1,04	1,22	1,12	0,93	0,95	0,84	0,84	1,01
handle json	0	0	0	0	0	0	0	0	0	0	0	0,00
created labels	0	0	0	0	0	0	0	0	0	0	0	0,00
custom v web request	1,38	1,18	1,42	1,30	1,04	1,28	1,12	1,54	1,34	1,27	1,22	1,28
hanlde json	0	0	0	0	0	0	0	0	0	0	0	0,00
created labels	0	0	0	0	0	0	0	0	0	0	0	0,00
<b>total</b>	<b>3,06</b>	<b>3,20</b>	<b>3,42</b>	<b>3,36</b>	<b>3,65</b>	<b>3,30</b>	<b>2,98</b>	<b>3,35</b>	<b>3,06</b>	<b>2,86</b>	<b>2,82</b>	<b>3,19</b>
Objekte durch obj det	4	3	0	0	2	0	2	4	1	2	0	1,64
Objekte durch custom	2	2	0	0	0	0	1	2	0	0	1	0,73

Abbildung 26: Laufzeitanalyse über 11 Bild-Analysen.




Abbildung 27: Diagramm Laufzeitanalyse

Gedanken dazu: Für die Laufzeit ist es besser ein einziges Network zu nehmen. Und das Image Capture so lange dauert ist eigentlich unacceptable. Das sollte schneller gehen. Dadurch statt einzelne Fotos aufzunehmen ein continuous video aufnehmen und frames davon zu analysieren wäre besser. Ist auf jeden Fall nicht real time.

Durchschnittlich wurden durch Objekt Detection 1.64 Objekte pro bild erkannt und durch custom detection 0.73.

## 5.2 Analyse durch Azure Objekt Detection

Wie sieht der Raum aus? Welche Objekte wurden erkannt. Wie wurden sie misinterpretet. Objekte erkennen auch wenn sie nicht komplett im Screen sind.

## 5.3 Azure Custom Vision

Kommt halt darauf an wie es trainiert ist.

#### 5.4 Objekte in 3D Szene Lokalisieren

generell gut. Durch mehrere detectionen wird lokation verbessert, besonders wenn durch leicht unterschiedliche Blickwinkel. Aber auch bei nur einer Erkennung ist die Position in der 3D Szene ganz gut.

spatial mapping braucht manchmal ne weisse, das dazu führt, das das label nicht an der richtigen stelle ist. passiert bei objekten die sich oft bewegen, wie ein stuhl. Siehe Abbildung 28.




Abbildung 28: Laufzeitanalyse

Halb Trasparente Objekte sind auch eine challenge für sptaial mapping. werden nicht richtig gemapped. Siehe Abbildung 29.




Abbildung 29: Label für Bottle liegt hinter dem Tatsächlichen Objekt. Die Flasche wurde nicht korrekt gemapped.

## 6 Zusammenfassung

In diesem Kapitel werden die bearbeiteten Themen kurz zusammengefasst.

### 6.1 Konzepte und Impelemntierte Funktionen

In dieser Arbeit wird Image based Objekt Detection in eine Augmented Reality Brille integriert, um eine automatisches Objekt Erkennen und Labeln zu ermöglichen.

Es werden Fotos von der Umgebung der AR Brille aufgenommen und mit einer Machine Learning Modell analysiert. Das Modell ist darauf trainiert Objekte und Lebewesen in einem Bild zu erkennen. Objekte auf den Fotos der Umgebung werden so auf den Fotos erkannt. Dann werden sie in der AR Umgebung lokalisiert und mit einem Label Markiert. Das automatische der Erkennen und Labeln von Objekten kann für große und dynamische Umgebungen verwendet werden. Es bietet somit eine gute Grundlage für AR Anwendungen die einer solchen Umgebung arbeiten oder eine ausgeprägteres Semantisches Verständnis der Umgebung benötigen. Beispielsweise eine Blindenführung in unbekannten Umgebungen, der Bereich des Autonomous Driving und Robotic.

### 6.2 Ausblick

Die Automatische Erkennung von Objekten in einer AR Umgebung ist funktionsfähig und effektiv.

Die Objekte, die erkannt werden hängen von dem verwendeten Machine Learning Modell ab. Es gibt die Arten der Objekte und die Genauigkeit der Detection an.

In Zukunft könnte man weitere Modelle verwenden um die Fotos der Umgebung zu analysieren. Beispielsweise können Kontextinformationen extrahiert werden. Daraus kann hervorheben, in welchem Raum eines Hauses die AR Brille sich befindet (Küche, Arbeitszimmer, Schlafzimmer).

Um die Lokalisierung eines Objektes in der AR Umgebung zu verbessern, könnte zusätzlich zu den Daten des Spatial Mappings, die Tiefenkamera der AR Brille verwendet werden. Die Spatial Map zu erstellen ist Arbeitsaufwändig. Das kann dazu führen Stellenweise die Map noch nicht aufgebaut ist, oder in einem Veralteten Zustand vorliegt, wenn ein Objekte lokalisiert werden soll. Die rohen Daten der Tiefenkamera könnten dazu verwendet werden, das Spatial Map zu ergänzen und zu korrigieren.

## 7 Literaturverzeichnis

### Azuma und Furmanski 2003

AZUMA, R. ; FURMANSKI, C.: Evaluating label placement for augmented reality view management. In: *The Second IEEE and ACM International Symposium on Mixed and Augmented Reality, 2003. Proceedings.*, 2003, S. 66–75

### Bell et al. 2001

BELL, Blaine ; FEINER, Steven ; HÖLLERER, Tobias: View Management for Virtual and Augmented Reality. In: *Proceedings of the 14th Annual ACM Symposium on User Interface Software and Technology*. New York, NY, USA : Association for Computing Machinery, 2001 (UIST '01). – ISBN 158113438X, 101–110

### Chen et al. 2018

CHEN, Long ; TANG, Wen ; JOHN, Nigel ; WAN, Tao R. ; ZHANG, Jian J.: *Context-Aware Mixed Reality: A Framework for Ubiquitous Interaction*. 2018

### Dörner et al. 2019

In: DÖRNER, Ralf ; BROLL, Wolfgang ; JUNG, Bernhard ; GRIMM, Paul ; GÖBEL, Martin: *Einführung in Virtual und Augmented Reality*. Berlin, Heidelberg : Springer Berlin Heidelberg, 2019. – ISBN 978-3-662-58861-1, 1–42

### Huynh et al. 2019

HUYNH, B. ; ORLOSKY, J. ; HÖLLERER, T.: In-Situ Labeling for Augmented Reality Language Learning. In: *2019 IEEE Conference on Virtual Reality and 3D User Interfaces (VR)*, 2019, S. 1606–1611

### Jiao et al. 2019

JIAO, L. ; ZHANG, F. ; LIU, F. ; YANG, S. ; LI, L. ; FENG, Z. ; QU, R.: A Survey of Deep Learning-Based Object Detection. In: *IEEE Access* 7 (2019), S. 128837–128868

### Jmour et al. 2018

JMOUR, N. ; ZAYEN, S. ; ABDELKRIM, A.: Convolutional neural networks for image classification. In: *2018 International Conference on Advanced Systems and Electric Technologies (IC ASET)*, 2018, S. 397–402

### Leap 2018

LEAP, Magic: *App Security*. <https://developer.magicleap.com/en-us/learn/guides/application-security-overview>. Version: 2018. – [Online; Stand 18. September 2020]

### MagicLeap

MAGICLEAP: *JsonUtility.FromJson*. <https://www.magicleap.care/hc/en-us>. – [Online; Stand 1. Oktober 2020]

### MagicLeap 2018

MAGICLEAP: *magic leap 1*. <https://www.magicleap.com/en-us/magic-leap-1>. Version: 2018. – [Online; Stand 18. September 2020]

### MagicLeap 2019a

MAGICLEAP: *Lumin OS Overview*. <https://developer.magicleap.com/en-us/learn/guides/lumin-os-overview>. Version: 2019. – [Online; Stand 18. September 2020]

### MagicLeap 2019b

MAGICLEAP: *World Rekonstruktion*. <https://developer.magicleap.com/en-us/>

learn/guides/world-reconstruction-overview-landing. Version: 2019. – [Online; Stand 18. September 2020]

#### **MagicLeap 2020a**

MAGICLEAP: *1.4 Spatial Meshing - Unity*. <https://developer.magicleap.com/en-us/learn/guides/meshing-in-unity>. Version: 2020. – [Online; Stand 18. September 2020]

#### **MagicLeap 2020b**

MAGICLEAP: *Glossary and Usage*. <https://developer.magicleap.com/en-us/learn/guides/glossary>. Version: 2020. – [Online; Stand 18. September 2020]

#### **MagicLeap 2020c**

MAGICLEAP: *Magic Leap Features*. <https://developer.magicleap.com/en-us/learn/guides/magic-leap-features>. Version: 2020. – [Online; Stand 18. September 2020]

#### **Maier et al. 2019**

MAIER, Andreas ; SYBEN, Christopher ; LASER, Tobias ; RIESS, Christian: A gentle introduction to deep learning in medical image processing. In: *Zeitschrift für Medizinische Physik* 29 (2019), Nr. 2, 86 - 101. <http://dx.doi.org/https://doi.org/10.1016/j.zemedi.2018.12.003>. – DOI <https://doi.org/10.1016/j.zemedi.2018.12.003>. – ISSN 0939–3889. – Special Issue: Deep Learning in Medical Physics

#### **Micosoft 2018**

MICOSOFT: *Mr und Azure 302b benutzerdefinierte Vision*. <https://docs.microsoft.com/de-de/windows/mixed-reality/mr-azure-302b>. Version: 2018. – [Online; Stand 17. September 2020]

#### **Microsoft**

MICROSOFT: *Microsoft Azure Computer Vsion*. <https://azure.microsoft.com/en-us/services/cognitive-services/computer-vision/>. – [Online; Stand 17. September 2020]

#### **Microsoft 2018a**

MICROSOFT: *Mr und Azure 302 Maschinelles Sehen*. <https://docs.microsoft.com/de-de/windows/mixed-reality/mr-azure-302>. Version: 2018. – [Online; Stand 17. September 2020]

#### **Microsoft 2018b**

MICROSOFT: *Spatial Mapping*. <https://docs.microsoft.com/de-de/windows/mixed-reality/spatial-mapping>. Version: 2018. – [Online; Stand 17. Septmber 2020]

#### **Microsoft 2019a**

MICROSOFT: *Detect common objects in images*. <https://docs.microsoft.com/en-us/azure/cognitive-services/computer-vision/concept-object-detection>. Version: 2019. – [Online; Stand 17. September 2020]

#### **Microsoft 2019b**

MICROSOFT: *Erkennen von alltäglichen Objekten in Bildern*. <https://docs.microsoft.com/de-de/azure/cognitive-services/computer-vision/concept-object-detection>. Version: 2019. – [Online; Stand 24. September 2020]

### **Microsoft 2020**

MICROSOFT: *What is Computer Vision.* <https://docs.microsoft.com/en-us/azure/cognitive-services/computer-vision/home>. Version: 2020. – [Online; Stand 17. September 2020]

### **O'Shea und Nash 2015**

O'SHEA, Keiron ; NASH, Ryan: An Introduction to Convolutional Neural Networks. In: *ArXiv e-prints* (2015), 11

### **Unity 2017**

UNITY: *GameObjects.* <https://docs.unity3d.com/Manual/GameObjects.html>. Version: 2017. – [Online; Stand 12. October 2020]

### **Unity 2018**

UNITY: *Prefabs.* <https://docs.unity3d.com/Manual/Prefabs.html>. Version: 2018. – [Online; Stand 12. October 2020]

### **Unity 2020a**

UNITY: *Camera.cameraToWorldMatrix.* <https://docs.unity3d.com/ScriptReference/Camera-cameraToWorldMatrix.html>. Version: 2020. – [Online; Stand 18. September 2020]

### **Unity 2020b**

UNITY: *JsonUtility.FromJson.* <https://docs.unity3d.com/ScriptReference/JsonUtility.FromJson.html>. Version: 2020. – [Online; Stand 24. September 2020]

### **Unity 2020c**

UNITY: *Matrix4x4.MultiplyPoint.* <https://docs.unity3d.com/ScriptReference/Matrix4x4.MultiplyPoint.html>. Version: 2020. – [Online; Stand 18. September 2020]

## 8 Anhang